

OTIMIZAÇÃO NÃO LINEARSEGUNDA LISTA DE EXERCÍCIOS

PEDRO GIGECK FREIRE

10737136

① Considere a função $f(x) = x_1^2 + 16x_2^2$ e $\sigma = 0.1$. Calcule um passo do método do gradiente para f com $x_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ e condição de Armijo com σ .

Para calcular a direção de descida, vamos calcular o vetor gradiente ∇f

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \frac{\partial f}{\partial x_2}(x) \end{pmatrix} = \begin{pmatrix} 2x_1 \\ 32x_2 \end{pmatrix}$$

Portanto, a direção de descida será

$$d = -\nabla f(x) = \begin{pmatrix} -2x_1 \\ -32x_2 \end{pmatrix}$$

No ponto $x_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$, a direção será $d = \begin{pmatrix} -2 \\ -32 \end{pmatrix}$

Agora, calculamos o passo que satisfaz a condição de Armijo com $\sigma = 0.1$

Ou seja, precisamos encontrar $\lambda > 0$ tal que

$$f(x_0 + \lambda d) \leq f(x_0) + \sigma \lambda \nabla f(x_0)^T d$$

Temos que

$$\bullet \quad x_0 + \lambda d = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \lambda \begin{pmatrix} -2 \\ -32 \end{pmatrix} = \begin{pmatrix} 1 - 2\lambda \\ 1 - 32\lambda \end{pmatrix}$$

$$\begin{aligned} \bullet \quad f(x_0 + \lambda d) &= f\left(\begin{pmatrix} 1 - 2\lambda \\ 1 - 32\lambda \end{pmatrix}\right) = (1 - 2\lambda)^2 + 16(1 - 32\lambda)^2 = 1 - 4\lambda + 4\lambda^2 + 16(1 - 64\lambda + 1024\lambda^2) \\ &= 16384\lambda^2 - 1028\lambda + 17 \end{aligned}$$

$$\bullet f(x_0) = 1 + 16 = 17$$

$$\bullet \sigma \lambda \nabla f(x_0)^T d = 0.1 \lambda \begin{pmatrix} 2 & 32 \end{pmatrix} \begin{pmatrix} -2 \\ -32 \end{pmatrix} = \lambda \cdot 0.1 \cdot (-4 - 1024) = \lambda \frac{(-1028)}{10}$$

Portanto,

$$f(x_0 + \lambda d) \leq f(x_0) + \sigma \lambda \nabla f(x_0)^T d \iff$$

$$16384 \lambda^2 - 1028 \lambda + 17 \leq 17 + \lambda \frac{(-1028)}{10} \iff$$

$$16384 \lambda^2 \leq \lambda \left(\frac{-1028}{10} + 1028 \right) \iff$$

$$16384 \lambda \leq \frac{9}{10} 1028 \quad (\text{pois } \lambda > 0) \iff$$

$$\lambda \leq \frac{9}{10} \frac{1028}{16384} \approx 0,05646 \dots$$

Logo, qualquer $\lambda \in (0, 0,0564]$ satisfaz a condição de Armijo. Para simplificar, podemos tomar $\lambda = 0,05 = \frac{1}{20}$

Assim, o primeiro passo do método do gradiente obterá

$$x_1 = x_0 + \lambda d = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + 0,05 \begin{pmatrix} -2 \\ -32 \end{pmatrix} = \begin{pmatrix} 1 - 0,1 \\ 1 - 0,16 \end{pmatrix} = \begin{pmatrix} 0,9 \\ 0,84 \end{pmatrix}$$

$$\text{Com } f(x_1) = (0,9)^2 + 16(0,84)^2 = 0,81 + 16 \cdot 0,7056 = 0,81 + 11,2896 = 12,0996$$

② Considere a função $f(x) = x_1^2 + 2x_1x_2 + 4x_2^2 + x_2x_3 + 16x_3^2$ e $\sigma = 0,1$. Calcule um passo do método do gradiente para f com $x_0 = (1, 1, 1)^T$ e condição de Armijo com σ .

Repetindo os passos do exercício anterior, vamos calcular o gradiente de f

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \frac{\partial f}{\partial x_2}(x) \\ \frac{\partial f}{\partial x_3}(x) \end{pmatrix} = \begin{pmatrix} 2x_1 + 2x_2 \\ 2x_1 + 8x_2 + x_3 \\ x_2 + 32x_3 \end{pmatrix}$$

Assim,

$$\nabla f(x_0) = \nabla f\left(\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}\right) = \begin{pmatrix} 2+2 \\ 2+8+1 \\ 1+32 \end{pmatrix} = \begin{pmatrix} 4 \\ 11 \\ 33 \end{pmatrix}$$

E a direção de descida será

$$d = \begin{pmatrix} -4 \\ -11 \\ -33 \end{pmatrix}$$

Para encontrar λ que satisfaz a condição de Armijo, calculamos os termos separadamente:

$$\bullet x_0 + \lambda d = (1, 1, 1)^T + \lambda (-4, -11, -33)^T = (1-4\lambda, 1-11\lambda, 1-33\lambda)^T$$

$$\bullet f(x_0 + \lambda d) = f((1-4\lambda, 1-11\lambda, 1-33\lambda)^T)$$

$$= (1-4\lambda)^2 + 2(1-4\lambda)(1-11\lambda) + 4(1-11\lambda)^2 + (1-11\lambda)(1-33\lambda) + 16(1-33\lambda)^2$$

$$= 1-8\lambda+16\lambda^2 + 2(1-11\lambda-4\lambda+44\lambda^2) + 4(1-22\lambda+121\lambda^2) + (1-44\lambda+363\lambda^2) + 16(1-66\lambda+1089\lambda^2)$$

$$= 1-8\lambda+16\lambda^2 + 2-30\lambda+88\lambda^2 + 4-88\lambda+484\lambda^2 + 1-44\lambda+363\lambda^2 + 16-1056\lambda+17424\lambda^2$$

$$= 18375\lambda^2 - 1226\lambda + 24$$

$$\bullet f(x_0) = f((1, 1, 1)^T) = 1 + 2 + 4 + 1 + 16 = 24$$

$$\bullet \sigma \lambda \nabla f(x_0)^T d = 0.1 \lambda (4, 11, 33) (-4, -11, -33)^T = \lambda 0.1 (-16 - 121 - 1089) = \lambda \frac{(-1226)}{10}$$

Portanto, para λ satisfazer a condição de Armijo com $\sigma = 0.1$, temos

$$f(x_0 + \lambda d) \leq f(x_0) + \sigma \lambda \nabla f(x_0)^T d \Leftrightarrow$$

$$18375\lambda^2 - 1226\lambda + 24 \leq 24 + \lambda \frac{(-1226)}{10} \Leftrightarrow$$

$$18375\lambda^2 \leq \lambda \frac{9}{10} 1226 \Leftrightarrow \text{pois } \lambda > 0$$

$$\lambda \leq \frac{9}{10} \frac{1226}{18375} \approx 0.06004$$

Logo, todo $\lambda \in (0, 0,06]$ satisfaz a condição de Armijo

Podemos tomar, portanto, o primeiro passo do método do gradiente $\lambda = 0,06$

Obtendo

$$\begin{aligned}\underline{x_1} &= x_0 + \lambda d = (1, 1, 1)^T + 0,06 (-4, -11, -33)^T = (1-0,24, 1-0,66, 1-1,98)^T \\ &= \underline{(0,76, 0,44, -0,98)}\end{aligned}$$

Com

$$\begin{aligned}\underline{f(x_1)} &= (0,76)^2 + 2(0,76 \cdot 0,44) + 4(0,44)^2 + (0,44)(-0,98) + 16(-0,98)^2 = \\ &= 0,5776 + 0,6688 + 0,7744 + (-0,4312) + 15,3664 = \underline{16,956}\end{aligned}$$

③ Sejam $f: \mathbb{R}^n \rightarrow \mathbb{R}$ com derivadas parciais contínuas, $x, d \in \mathbb{R}^n$ e $\lambda > 0$ tais que $x + \lambda d$ satisfaz a condição de Armijo com constante σ . Seja $\mu \in (0, \lambda)$. $x + \mu d$ satisfaz a mesma condição de Armijo? Prove ou dê um contra exemplo.

Não. $x + \mu d$ não necessariamente satisfaz a condição de Armijo.


Contra exemplo:

Considere $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ dada por

$$f(x_1, x_2) = x_1^2 - x_1^3$$

Tome $x = (-1, 0)$ e $d = (1, 0)$. Considere $\sigma = 0,25 = 1/4$.

Esboçando a função (de uma variável) $f(x + \lambda d) = f((\lambda-1, 0)) = (\lambda-1)^2 - (\lambda-1)^3$



Agora, vamos colocar no gráfico o lado esquerdo da condição de Armijo


$$f(x) + \sigma \lambda \nabla f(x)^T d$$

Antes, calculemos o gradiente no ponto $x = (-1, 0)$

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \frac{\partial f}{\partial x_2}(x) \end{pmatrix} = \begin{pmatrix} 2x_1 - 3x_1^2(x) \\ 0 \end{pmatrix} = \begin{pmatrix} -2 - 3 \\ 0 \end{pmatrix} = \begin{pmatrix} -5 \\ 0 \end{pmatrix}$$

Portanto $f(x) + \sigma \lambda \nabla f(x)^T d = (-1)^2 - (-1)^3 + \frac{1}{4} \lambda (-5 \ 0) (1 \ 0)^T$

$$= 2 + \lambda(-5) = 2 - \frac{5}{4} \lambda$$



Portanto, se tomarmos $\lambda = 4$, a condição de Armijo será satisfeita:

$$f(x+4d) \leq f(x) + \sigma 4 \nabla f(x)^T d \Leftrightarrow$$

$$f((-1+4, 0)) \leq f((-1, 0)) + \frac{4}{4} (-5, 0) (1, 0)^T \Leftrightarrow$$

$$(-5)^2 - (-5)^3 \leq (-1)^2 - (-1)^3 + 1 \cdot (-5) \Leftrightarrow$$

$$25 - 125 \leq 1 - 1 - 5 \Leftrightarrow$$

$$-100 \leq -5$$



(de fato, satisfaz)

Porém, quando tomamos $\mu = 2$, a condição de Armijo não é satisfeita:

$$f(x+2d) \leq f(x) + \sigma 2 \nabla f(x)^T d \Leftrightarrow$$

$$f((-1+2, 0)) \leq (-1)^2 - (-1)^3 + \frac{2}{4} (-5 \ 0) (1 \ 0)^T \Leftrightarrow$$

$$1^2 - 1^3 \leq 1 - 1 + \frac{1}{2} (-5) \Leftrightarrow$$

$$0 \leq -\frac{5}{2} \quad \underline{\text{FALSO}}$$

De fato, a condição de Armijo é satisfeita com $\lambda = 4$ mas não é satisfeita com $\mu = 2$.

④ Sejam $f: \mathbb{R}^n \rightarrow \mathbb{R}$ com derivadas parciais de segunda ordem contínuas e $\bar{x} \in \mathbb{R}^n$ tal que $\nabla f(\bar{x}) = 0$ e suponha que $\nabla^2 f(\bar{x})$ não é semidefinida positiva. Mostre que existe uma direção de descida em \bar{x} .

Vamos utilizar a mesma ideia vista em aula para provar a condição de optimalidade de segunda ordem:

Como $\nabla^2 f(\bar{x})$ não é semidefinida positiva, então existe $d \in \mathbb{R}^n$ tal que

$$d^T \nabla^2 f(\bar{x}) d < 0.$$

Agora podemos utilizar a aproximação de segunda ordem de f para mostrar que d é uma direção de descida

Temos que

$$f(\bar{x} + d) = f(\bar{x}) + \nabla f(\bar{x})^T d + \frac{1}{2} d^T \nabla^2 f(\bar{x}) d + o(\|d\|^2)$$

$$= f(\bar{x}) + \frac{1}{2} d^T \nabla^2 f(\bar{x}) d + o(\|d\|^2) \quad (\text{pois } \nabla f(\bar{x}) = 0)$$

$$< f(\bar{x}) + o(\|d\|^2) \quad (\text{pois } d^T \nabla^2 f(\bar{x}) d < 0)$$

Portanto, para $\|d\|$ suficientemente pequeno, teremos que

$$f(\bar{x} + d) < f(\bar{x})$$

Logo, d é uma direção de descida.

⑤ Sejam $f: \mathbb{R}^n \rightarrow \mathbb{R}$ e $\bar{x} \in \mathbb{R}^n$ tal que $\nabla f(\bar{x}) \neq 0$. Se $M \in \mathbb{R}^{n \times n}$ é positiva definida, mostre que $d = -M \nabla f(\bar{x})$ é uma direção de descida.

Vamos usar a aproximação de 1ª ordem para $f(\bar{x} + (-M \nabla f(\bar{x})))$

$$f(\bar{x} - M \nabla f(\bar{x})) = f(\bar{x}) + \nabla f(\bar{x})^T (-M \nabla f(\bar{x})) + o(\| -M \nabla f(\bar{x}) \|)$$

$$= f(\bar{x}) - \nabla f(\bar{x})^T M \nabla f(\bar{x}) + o(\| -M \nabla f(\bar{x}) \|)$$

$$< f(\bar{x}) + o(\| -M \nabla f(\bar{x}) \|) \quad \text{pois} \quad \nabla f(\bar{x})^T M \nabla f(\bar{x}) > 0 \quad \text{já que} \\ M \text{ é positiva definida.}$$

Logo, multiplicando $-M \nabla f(\bar{x})$ por uma constante λ suficientemente pequena, teremos

$$f(\bar{x} - \lambda M \nabla f(\bar{x})) < f(\bar{x})$$

Portanto $-M \nabla f(\bar{x})$ é uma direção de descida.

⑥ Considere o método do gradiente com busca linear exata, isto é, x_{k+1} é o minimizador local de f ao longo da reta $\{x_k - t \nabla f(x_k), t \in \mathbb{R}\}$. Prove que $\nabla f(x_{k+1})^T \nabla f(x_k) = 0$.

Considere f ao longo da reta $\{x_k - t \nabla f(x_k) : t \in \mathbb{R}\}$, isto é, seja

$$\varphi: \mathbb{R} \rightarrow \mathbb{R} \quad \text{dada por} \quad \varphi(t) = f(x_k - t \nabla f(x_k))$$

Note que

$$\varphi'(t) = \nabla f(x_k - t \nabla f(x_k))^T (-\nabla f(x_k))$$

Agora consideremos um ponto t^* de mínimo local de f .

Como t^* é mínimo local, então $\varphi'(t^*) = 0$

Além disso, como x_{k+1} é o ponto de mínimo local de f ao longo da reta $\{x_k - t \nabla f(x_k) : t \in \mathbb{R}\}$, então

$$x_{k+1} = x_k - t^* \nabla f(x_k)$$

Portanto

$$\begin{aligned} 0 = \varphi'(t^*) &= \nabla f(x_k - t^* \nabla f(x_k))^T (-\nabla f(x_k)) \\ &= -\nabla f(x_{k+1})^T \nabla f(x_k) \end{aligned}$$

$$\text{De fato, } \nabla f(x_{k+1})^T \nabla f(x_k) = 0$$

⌚ Seja $f: \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciável em \bar{x} e sejam $d^1, \dots, d^n \in \mathbb{R}^n$ vetores linearmente independentes. Suponha que o mínimo de $g_j(\lambda) = f(\bar{x} + \lambda d^j)$ ocorra em $\lambda = 0$ para $j = 1, \dots, n$. Prove que $\nabla f(\bar{x}) = 0$. Isso implica que f tem um mínimo local em \bar{x} ?

Note que, para todo $j = 1, 2, \dots, n$

$$g_j'(\lambda) = \nabla f(\bar{x} + \lambda d^j)^T d^j$$

E que $g_j'(0) = 0$ pois $\lambda = 0$ é mínimo de g_j .

Então

$$0 = g_j'(0) = \nabla f(\bar{x})^T d^j$$

Podemos somar todas as $g_j'(0)$ e obter

$$0 = \sum_{j=1}^n g_j'(0) = \sum_{j=1}^n \nabla f(\bar{x})^T d^j = \nabla f(\bar{x})^T \left(\sum_{j=1}^n d^j \right)$$

Isso implica que $\nabla f(\bar{x}) = 0$ pois d^j são linearmente independentes, portanto os coeficientes da soma têm que ser todos zero.

Vamos verificar que f tem mínimo local em \bar{x} .

Note que, para todo $j = 1, 2, \dots, n$

$$\begin{aligned} g_j''(\lambda) &= \left[\nabla^2 f(\bar{x} + \lambda d^j)^T d^j \right]^T d^j \\ &= d^{jT} \nabla^2 f(\bar{x} + \lambda d^j) d^j \end{aligned}$$

E como $\lambda = 0$ é mínimo local de g_j , temos que

$$d^{jT} \nabla^2 f(\bar{x}) d^j = g_j''(0) \geq 0$$

Logo, como $\{d^j : j = 1, \dots, n\}$ é um conjunto linearmente independente, temos que é uma base de \mathbb{R}^n . Então todo vetor $x \in \mathbb{R}^n$ pode ser decomposto em uma combinação linear dos d^j , $x = a_1 d^1 + \dots + a_n d^n$ ($a_j \in \mathbb{R}$, $j = 1, \dots, n$).

$$\begin{aligned} \text{Portanto } x^T \nabla^2 f(\bar{x}) x &= (a_1 d^1 + \dots + a_n d^n)^T \nabla^2 f(\bar{x}) (a_1 d^1 + \dots + a_n d^n) \\ &= (a_1 d^1)^T \nabla^2 f(\bar{x}) (a_1 d^1) + \dots + (a_n d^n)^T \nabla^2 f(\bar{x}) (a_n d^n) \\ &= a_1^2 d^{1T} \nabla^2 f(\bar{x}) d^1 + \dots + a_n^2 d^{nT} \nabla^2 f(\bar{x}) d^n \\ &= a_1^2 g_1''(0) + \dots + a_n^2 g_n''(0) \\ &\geq 0 \quad \text{pois } a_j^2 \geq 0 \text{ e } g_j''(0) \geq 0 \end{aligned}$$

Isto é, $\nabla^2 f(\bar{x})$ é uma matriz semidefinida positiva. Isso implica que f tem mínimo local em \bar{x} .

⑧ Seja

$$f(x) = \frac{1}{2}(x_1 - x_2)^2 + \frac{1}{2}(1 - x_1)^2$$

Qual é o minimizador de f ? Faça uma iteração do método de Newton para f a partir de $x_0 = (2, 2)^T$ com $\lambda = 1$. É um bom ponto? Antes de decidir, calcule $f(x_0)$ e $f(x_1)$.

- Vamos calcular o mínimo de f :

Temos que

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \frac{\partial f}{\partial x_2}(x) \end{pmatrix} = \begin{pmatrix} (x_1 - x_2) - (1 - x_1) \\ -(x_1 - x_2) \end{pmatrix} = \begin{pmatrix} 2x_1 - x_2 - 1 \\ x_2 - x_1 \end{pmatrix}$$

De modo que

$$\nabla f(x) = 0 \iff \begin{cases} 2x_1 - x_2 - 1 = 0 \\ x_2 - x_1 = 0 \end{cases} \iff x_1 = x_2 = 1$$

Como $f(1, 1) = 0$ e $f(x) \geq 0$ para todo $x \in \mathbb{R}^2$, então

$\bar{x} = (1, 1)^T$ é minimizador de f .

- Agora, vamos fazer uma iteração do método de Newton, com $x_0 = (2, 2)^T$ e $\lambda = 1$.

$$\text{Antes, calculemos } \nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2^2} \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} \text{ para todo } x \in \mathbb{R}^n$$

$$\text{E a inversa é } \nabla^2 f(x)^{-1} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$$

Então a direção de descida será

$$- \nabla^2 f(x_0)^{-1} \nabla f(x_0) = - \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 4 - 2 - 1 \\ 2 - 2 \end{pmatrix} = - \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = - \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Com o passo $\lambda = 1$, obteremos

$$x_1 = x_0 + \lambda d = (2, 2)^T + (-1, -1)^T = (1, 1)^T$$

Que é o mínimo da função!

Portanto o método precisou de apenas uma iteração para chegar na resposta.

Na primeira iteração tínhamos $f(x_0) = \frac{1}{2}$

Na segunda, teremos $f(x_1) = 0$

Ou seja, $\lambda = 1$ foi um bom ponto, nesse caso.

9) Obtenha uma base para o núcleo da Matriz

$$A = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{pmatrix}$$

e encontre $x \in \mathbb{R}^4$ tal que $Ax = (1, 2)^T$

Vamos calcular o escalonamento de A

$$A = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{pmatrix}$$

subtraímos 5 vezes a linha 1 da linha 2

$$\begin{pmatrix} 1 & 2 & 3 & 4 \\ 0 & -4 & -8 & -12 \end{pmatrix}$$

Agora multiplicamos a linha 2 por $-\frac{1}{4}$

$$\begin{pmatrix} 1 & 2 & 3 & 4 \\ 0 & 1 & 2 & 3 \end{pmatrix}$$

Por fim, subtraímos 2 vezes a linha 2 da linha 1

$$\begin{pmatrix} 1 & 0 & -1 & -2 \\ 0 & 1 & 2 & 3 \end{pmatrix}$$

Agora, podemos calcular o núcleo da matriz escalonada

Teremos

$$\begin{pmatrix} 1 & 0 & -1 & -2 \\ 0 & 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ w \end{pmatrix} = 0 \iff \begin{cases} x - z - 2w = 0 \\ y + 2z + 3w = 0 \end{cases} \iff \begin{cases} x = z + 2w \\ y = -2z - 3w \end{cases}$$

$$\text{Então } x = (z + 2w, -2z - 3w, z, w)^T = \begin{pmatrix} 1 \\ -2 \\ 1 \\ 0 \end{pmatrix} z + \begin{pmatrix} 2 \\ -3 \\ 0 \\ 1 \end{pmatrix} w$$

Ou seja, os vetores $\begin{pmatrix} 1 \\ -2 \\ 1 \\ 0 \end{pmatrix}$ e $\begin{pmatrix} 2 \\ -3 \\ 0 \\ 1 \end{pmatrix}$ formam uma base do núcleo de A .

• Por fim, vamos resolver o sistema $Ax = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$

$$\begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ w \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \iff \begin{cases} x + 2y + 3z + 4w = 1 \\ 5x + 6y + 7z + 8w = 2 \end{cases}$$

E podemos tomar $z = w = 0$ e obter o sistema $\begin{cases} x + 2y = 1 \\ 5x + 6y = 2 \end{cases}$

$$\iff \begin{cases} 5x + 10y = 5 \\ 5x + 6y = 2 \end{cases} \iff 4y = 3 \iff y = \frac{4}{3}, \quad x = 2y - 1 = \frac{8}{3} - 1 = \frac{5}{3}$$

Obtemos, portanto, a solução $\begin{pmatrix} 5/3 \\ 4/3 \\ 0 \\ 0 \end{pmatrix}$

10) Obtenha uma base para o núcleo da matriz

$$A = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \\ 7 & 10 & 13 & 16 \end{pmatrix}$$

e mostre que não existe $x \in \mathbb{R}^4$ tal que $Ax = (1, 2, 3)^T$

Primeiramente, escalonamos a matriz A : (partindo já da versão escalonada do exercício anterior:

$$A = \begin{pmatrix} 1 & 0 & -1 & -2 \\ 0 & 1 & 2 & 3 \\ 2 & 10 & 13 & 16 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 0 & -1 & -2 \\ 0 & 1 & 2 & 3 \\ 0 & -10 & 20 & 30 \end{pmatrix}$$

subtraindo 7 vezes a primeira linha da terceira

$$\begin{pmatrix} 1 & 0 & -1 & -2 \\ 0 & 1 & 2 & 3 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

subtraindo 10 vezes a segunda linha da última

Portanto, vemos que a matriz A não tem posto máximo

Achando uma base para o núcleo, obteremos a mesma do exercício 9:

$$\left\{ \begin{pmatrix} 1 \\ -2 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 2 \\ 3 \\ 0 \\ 1 \end{pmatrix} \right\}$$

Agora, podemos provar que não existe x tal que $Ax = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$

mostrando que esse vetor $\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$ não é perpendicular ao núcleo, ou seja, não está na imagem de A .

Obtemos, da forma escalonada, que as colunas 1 e 2 da matriz A formam uma base do espaço coluna.

Portanto o espaço coluna é gerado por

$$\begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} x + \begin{pmatrix} 2 \\ 6 \\ 10 \end{pmatrix} y \quad (x, y \in \mathbb{R})$$

E conferimos que o sistema

$$\begin{cases} x + 2y = 1 \\ 5x + 6y = 2 \\ 7x + 10y = 3 \end{cases}$$

Não tem solução.